

Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет ИТМО»
Факультет Программной инженерии и Компьютерной техники

**Отчёт по лабораторной работе №3
по Системам Искусственного Интеллекта
Линейная регрессия
Вариант 16**

**Выполнили:
Бондаренко Андрей
Снагин Станислав
Преподаватель:
Жданов Андрей
Дмитриевич**

Санкт-Петербург 2026г.

Содержание

Постановка задачи	3
Разведочный анализ данных	3
Метод	3
Результаты	4
Модель 1: базовые признаки	4
Модель 2: + сон и пробные работы	4
Модель 3: все признаки	4
Сравнение моделей	5
Бонус: синтетический признак	5
Выводы	5

Постановка задачи

Цель — построить модель множественной линейной регрессии для предсказания индекса успеваемости студентов по набору признаков.

Датасет: Student Performance (10 000 записей).

Признаки: часы учёбы, прошлые баллы, внеклассная активность (Yes/No), часы сна, число пробных работ.

Целевая переменная: Performance Index (10–100).

Задачи:

1. Разведочный анализ данных.
2. Предобработка: кодирование категориального признака, нормировка, split.
3. Реализация МНК в матричной форме (только NumPy/Pandas).
4. Три модели с разными наборами признаков, сравнение по R^2 .
5. Бонус: синтетический признак.

Разведочный анализ данных

Пропусков нет. Распределение категориального признака: No — 5052, Yes — 4948 (сбалансировано).

признак	mean	std	min	25%	50%	75%	max
Hours Studied	4.99	2.59	1	3	5	7	9
Previous Scores	69.45	17.34	40	54	69	85	99
Sleep Hours	6.53	1.70	4	5	7	8	9
Sample Papers	4.58	2.87	0	2	5	7	9
Performance Index	55.22	19.21	10	40	55	71	100

Описательная статистика (посчитана вручную).

Матрица корреляции (фрагмент, столбец Performance Index):

признак	r с таргетом	комментарий
Hours Studied	0.37	средняя связь
Previous Scores	0.92	сильная связь
Sleep Hours	0.05	слабая
Sample Papers	0.04	слабая

Корреляция признаков с целевой переменной.

Вывод: главный предиктор — Previous Scores. Hours Studied — второй по силе.

Остальные признаки слабо связаны с таргетом. Между самими признаками сильных корреляций нет — мультиколлинеарности не ожидается.

Метод

Модель: $y = a + b_1x_1 + \dots + b_px_p + \varepsilon$.

МНК в матричной форме:

$$B = (X'X)^{-1}X'Y,$$

где X — матрица признаков с добавленным столбцом единиц (для свободного члена), Y — вектор целевых значений.

Предобработка:

- Yes/No $\rightarrow$ 1/0.
- Z-нормировка: $(x - \bar{x})/\sigma$, статистики считаются только по train.
- Отношение объёма данных для обучения к данным на проверку 80/20

Метрики: R^2 , MSE, MAE. Реализованы вручную на NumPy.

Результаты

Модель 1: базовые признаки

Признаки: Hours Studied, Previous Scores.

intercept	55.3115
Hours Studied	7.4165
Previous Scores	17.6450

R^2 train = 0.9859, R^2 test = 0.9859, MSE = 5.2419, MAE = 1.8269.

Модель 2: + сон и пробные работы

Добавлены Sleep Hours, Sample Question Papers Practiced.

intercept	55.3115
Hours Studied	7.4029
Previous Scores	17.6392
Sleep Hours	0.8039
Sample Papers	0.5486

R^2 train = 0.9884, R^2 test = 0.9887, MSE = 4.1823, MAE = 1.6297.

Модель 3: все признаки

Добавлен Extracurricular Activities.

intercept	55.3115
Hours Studied	7.4018
Previous Scores	17.6384
Extracurricular Activities	0.3043
Sleep Hours	0.8101
Sample Papers	0.5489

R^2 train = 0.9887, R^2 test = 0.9890, MSE = 4.0826, MAE = 1.6111.

Сравнение моделей

модель	R^2 train	R^2 test	MSE	MAE
1: базовые	0.9859	0.9859	5.2419	1.8269
2: +сон, +пробные	0.9884	0.9887	4.1823	1.6297
3: все	0.9887	0.9890	4.0826	1.6111

Сравнение трёх моделей.

Выводы:

- Модель 1 уже объясняет 98.6% дисперсии — два признака дают почти всё.
- Добавление Sleep Hours и Sample Papers даёт прирост $\Delta R^2 \approx 0.003$.
- Extracurricular Activities даёт исчезающе малый прирост ($\Delta R^2 \approx 0.0003$).
- R^2 train и test совпадают — переобучения нет.

Бонус: синтетический признак

Добавлен `Study_x_Prev = Hours Studied × Previous Scores`.

R^2 test = 0.9890 — **не изменился** относительно модели 3. Коэффициент при синтетическом признаке близок к нулю.

Вывод: признак бесполезен. Причина — Hours Studied и Previous Scores почти не коррелируют ($r \approx -0.01$), поэтому их произведение не несёт новой информации.

Выводы

В работе реализована множественная линейная регрессия МНК в матричной форме. Выяснили что пропусков нет, выполнена предобработка: кодирование категориального признака Yes/No в 0/1, Z-нормировка по статистикам обучающей выборки, разделение 80/20. Построены три модели с разными наборами признаков, для каждой рассчитаны коэффициенты и метрики качества (R^2 , MSE, MAE), а также проверен синтетический признак — произведение часов учёбы и прошлых баллов.

Наилучший результат показала модель со всеми признаками: $R^2 = 0.9890$. Основной вклад вносят Previous Scores (коэффициент 17.64) и Hours Studied (7.40); добавление Sleep Hours и Sample Question Papers Practiced даёт прирост $\Delta R^2 \approx 0.003$, а Extracurricular Activities — лишь $\Delta R^2 \approx 0.0003$. Синтетический признак Study_x_Prev прироста не дал (R^2 остался 0.9890, коэффициент 0.0112), что объясняется отсутствием корреляции между исходными признаками ($r \approx -0.01$). R^2 на train и test совпадают, что говорит об отсутствии переобучения.

Ограничения: датасет синтетический, признаки генерировались независимо, поэтому линейная модель почти оптимальна.

Используемые промты для нейросети

1. при печати pandas сворачивает столбцы и ставит ... как вывести таблицу целиком без сворачивания чтобы каждый столбец был виден
2. вот в этом файле список словарей вывожу через f-string но колонки не выравниваются сделай вывод таблицей с выравниванием по правому краю и разделителем и чтобы выглядело адекватно

3. `visualize_data` вызывает `plt.show` нужно чтобы графики сохранялись в папку `plots` с фиксированными именами а окно не открывалось как исправить на `plt.savefig` и `plt.close`
4. здесь ошибка `ValueError` в столбце `extracurricular activities` есть значения отличные от `yes` но я добавил синтетический признак и теперь `prepare_data` падае. почему так и как исправить
5. вот в этом файле `prepare_data` вызывается для каждого кандидата и каждый раз делает `split` заново это же долго и тупо. переделай чтобы `split` был один раз а признаки добавлялись поверх
6. вывод таблицы съезжает когда названия признаков длинные сделай нормальное выравнивание блн